

Exercise 1:

[cat, dog, eats, fish, likes]

$$D_1 = [1, 0, 1, 1, 0]$$

$$D_2 = [0, 1, 1, 1, 0]$$

$$D_3 = [1, 0, 0, 1, 1]$$

Exercise 2:

$$tf(cat, D_1) = \frac{1}{3}$$

$$tf(eats, D_1) = \frac{1}{3}$$

$$tf(fish, D_1) = \frac{1}{3}$$

$$\sum_t tf(t, D_1) = tf(cat, D_1) + tf(eats, D_1) + tf(fish, D_1) = 1$$

Exercise 3:

$$idf(cat) = \log \frac{3}{2}$$

$$idf(fish) = 0$$

$$idf(dog) = \log 3$$

$$idf(likes) = \log 3$$

$$idf(eats) = \log \frac{3}{2}$$

Term "fish" có IDF thấp nhất.
Đễ thấy term có DF càng cao thì giá trị IDF càng thấp. Do "fish" có giá trị DF cao nhất trong tất cả các

term nên "fish" sẽ có giá trị IDF thấp nhất.

Exercise 4:

$$\text{tfidf}(\text{cat}, D_1) = \text{tf}(\text{cat}, D_1) \cdot \text{idf}(\text{cat})$$
$$= \frac{1}{3} \cdot \log \frac{3}{2}$$

$$\text{tfidf}(\text{eats}, D_1) = \text{tf}(\text{eats}, D_1) \cdot \text{idf}(\text{eats})$$
$$= \frac{1}{3} \cdot \log \frac{3}{2}$$

$$\text{tfidf}(\text{fish}, D_1) = \text{tf}(\text{fish}, D_1) \cdot \text{idf}(\text{fish})$$
$$= \frac{1}{3} \cdot 0 = 0$$

Do "fish" xuất hiện trong mọi document nên giá trị DF của nó bằng tổng các document theo công thức tính IDF, IDF của "fish" bằng 0. $\Rightarrow$ TF-IDF của "fish" bằng 0.

Exercise 5:

$$\cos(x, y) = \frac{x^T y}{\|x\|_2 \|y\|_2} = \frac{1 \cdot 1 + 1 \cdot 1 + 1 \cdot 0}{\sqrt{3} \cdot \sqrt{2}}$$
$$= \frac{2}{\sqrt{6}}$$

Công thức cosine similarity sử dụng để đo mức độ giống nhau về hướng của 2 vector, không đo tỷ lệ số term giống nhau trên tổng số term nên cosine similarity ở đây bằng $2/\sqrt{6}$, không phải $2/3$.

Exercise 6:

[medical, image, classification, analysis,
natural, language, processing].

$$D_1 = [1, 1, 1, 0, 0, 0, 0]$$

$$D_2 = [1, 1, 0, 1, 0, 0, 0]$$

$$D_3 = [0, 0, 0, 0, 1, 1, 1]$$

$$Q = [1, 1, 1, 0, 0, 0, 0]$$

$$\cos(Q, D_1) = \frac{Q^T D_1}{\|Q\|_2 \|D_1\|_2} = \frac{1+1+1+0+0+0+0}{\sqrt{3} \cdot \sqrt{3}}$$

$$\cos(Q, D_2) = \frac{Q^T D_2}{\|Q\|_2 \|D_2\|_2} = \frac{1+1+0+0+0+0+0}{\sqrt{3} \cdot \sqrt{3}}$$

$$\cos(Q, D_3) = \frac{Q^T D_3}{\|Q\|_2 \|D_3\|_3} = \frac{0}{\sqrt{3} \cdot \sqrt{3}}$$

1. Document D_1 có similarity cao nhất.
2. Document D_3 có similarity thấp nhất.
3. "medical", "image" có giá trị IDF thấp nhất.
4. Nếu sử dụng count vector thay vì IDF thì ~~có thể~~ thay đổi ranking.
Không