

Part 1, Error Analysis

2 query có kết quả tốt.
+ "data mining algorithm"

1, D4158 đứng đầu do chứa nhiều từ liên quan đến "data", "algorithm" và có similarity cao (0,3992).

2, "data", "algorithm" đóng góp nhiều vào similarity.

3, Có xuất hiện lexical overlap.

4, Relevant document xuất hiện ở rank thứ 2.

5, Failure xuất phát từ việc TF-IDF dựa vào lexical matching, tập trung vào "big data" và "algorithm".
+ "heart attack treatment"

1, D9048 đứng đầu về similarity.

2, "attack" đóng góp nhiều vào similarity.

3, Có xuất hiện lexical overlap.

4, Relevant document xuất hiện ở rank thứ 2.

5, Failure xuất phát từ việc TF-IDF dựa vào lexical matching, tập trung vào "attack".

2 query có kết quả tệ.

"medical image classification"

1, D27352 đứng đầu về similarity.

2, "classification" và "image" đóng góp nhiều vào similarity.

3, Có xuất hiện lexical overlap.

4, Không xuất hiện relevant document.

5, Failure xuất phát từ việc TF-IDF tập trung vào lexical matching, dẫn đến khác biệt về mặt ý nghĩa document với query.

"transformer language model"

1, D6326 đứng đầu về similarity.

2, "transformer" và "model" đóng góp nhiều vào similarity.

3, Có xuất hiện lexical overlap.

4, Không xuất hiện lexical overlap.

5, Failure xuất phát khi TF-IDF chú trọng vào lexical matching, bỏ qua ý nghĩa của từ.

Part J: From Failure to the Next NLP representation
Làm thế nào để biểu diễn được ~~đ~~ similarity về nghĩa thay vì chỉ similarity về từ?

Cần có biểu diễn (representation) về các từ có context tương tự và xuất hiện gần nhau. Thay vì biểu diễn dạng sparse, việc biểu diễn dạng dense có thể tính đến ~~đ~~ so sánh similarity về nghĩa của các từ, đó là nền tảng cho word embedding về sau.

Learning Check:

Q1: Mỗi document sau khi biểu diễn TF-IDF tạo ra biểu diễn dạng sparse do ~~th~~ ít vocab từ.

bộ term được xây dựng trên toàn corpus.

Q2: Một term xuất hiện nhiều ở hầu hết các doc thì mức độ nhận diện/quan trọng càng giảm đi, do đó dẫn đến IDF thấp.

Q3: Do chưa chắc term xuất hiện trong document nên TF có thể bằng 0, do đó, TF-IDF của từ trên document bằng 0.

Q4: cosine similarity đo mức độ giống nhau về hướng giữa 2 document vectors, hay nói cách khác đo độ tương đồng giữa 2 document.

Q5: Vì mỗi pre processing pipeline quyết định cách xử lý term và tạo bộ vocab sử dụng để vectorize các document.

Q6: Đó là "medical image classification" khi trả về những "classification" trong phần mềm thống kê và không cùng

Về nghĩa.

QT: Cần phải có phương pháp xử lý Contextual representation
Chẳng hạn như word embeddings.

Part K: Reflection.

1, Prediction về Vocabulary, khi thực tế có đến hơn 400 K terms.

2, kết quả truy vấn query của "medical image Classification"

3, Experiment 2 cung cấp evidence mạnh nhất về kết quả search query trên corpus 30 K documents?

4, Failure case quan trọng trong bài là query "~~Medical~~ không có relevant document do không có tính tương đồng về nghĩa của từ."

5, Em sẽ giữ lại TF-IDF và có thể cải tiến một số phương pháp biểu diễn khác như word embeddings.

6, AI có đóng góp ở những phần như:

+ Hỗ trợ phần implementation.

+ Gợi ý xây dựng pipeline preprocess. và search Engine.